

FireRisk — Bassin Méditerranéen

Prédiction du risque d'incendie de forêt par Deep Learning

LSTM · TCN · ERA5 · MODIS NDVI · NASA FIRMS

Institut National des Postes et Télécommunications — INPT

Filière : DATA | Module : Deep Learning

Réalisé par :

Ilyass Aamoum
Chihab Chouai

Encadrant :

Mr. Tarik Fissaa

Période d'étude : 2022–2024

Entraînement : 2022 | Test : 2023 (données jamais vues)

19 mai 2026

Table des matières

Résumé	2
1 Introduction	3
1.1 Contexte et motivation	3
1.2 Problématique	3
1.3 Contributions du projet	4
1.4 Organisation du rapport	4
2 Zone d'étude et Sources de données	5
2.1 Zone d'étude : le bassin méditerranéen	5
2.2 Source 1 : ERA5 — Réanalyse atmosphérique ECMWF	5
2.2.1 Variables utilisées	6
2.2.2 Traitement des données ERA5	6
2.2.3 Calcul de l'humidité relative	6
2.2.4 Calcul de la vitesse du vent	7
2.3 Source 2 : MODIS NDVI — Végétation satellite	7
2.3.1 Description du produit MODIS	7
2.3.2 Justification de la réutilisation de 2022 comme référence NDVI .	8
2.3.3 Traitement des fichiers GeoTIFF	8
2.4 Source 3 : NASA FIRMS — Détections actives d'incendies	9
2.4.1 Description	9
2.4.2 Traitement et grillage	9

3	Ingénierie des Features et Construction du Dataset	10
3.1	Les 8 features d'entrée	10
3.2	Features dérivées	10
3.2.1	Indice de sécheresse	10
3.3	Variable cible : le Risk Score	11
3.3.1	Définition	11
3.3.2	Normalisation	11
3.3.3	Niveaux de risque	12
3.4	Construction du tenseur d'apprentissage	12
3.4.1	Forme des arrays	12
3.4.2	Fenêtres glissantes	12
3.4.3	Normalisation (scaler)	13
3.5	Split temporel	13
4	Architectures des Modèles de Deep Learning	14
4.1	Vue d'ensemble	14
4.2	LSTM — Long Short-Term Memory	14
4.2.1	Description de l'architecture	15
4.2.2	Nombre de paramètres	16
4.3	TCN — Temporal Convolutional Network	16
4.3.1	Blocs résiduels causaux	16
4.3.2	Champ réceptif	17
4.3.3	Global Average Pooling	17
4.3.4	Comparaison des architectures	17
5	Protocole d'Entraînement	18
5.1	Déséquilibre de classes et stratégies de correction	18
5.1.1	Perte Weighted MSE	18
5.1.2	Weighted Random Sampler	18
5.2	Optimisation et régularisation	19

5.3	Early Stopping	19
5.4	Courbes d'apprentissage	19
6	Évaluation et Résultats	21
6.1	Protocole d'évaluation	21
6.2	Métriques d'évaluation	21
6.2.1	Métriques de régression	21
6.2.2	Métrique de classification	22
6.3	Résultats quantitatifs	22
6.4	Analyse des prédictions	22
6.4.1	Exemples à fort risque validés	22
6.4.2	Cartes de risque	23
6.5	Discussion des performances	23
7	Architecture Logicielle du Système	24
7.1	Structure du projet	25
7.2	Flux de données	26
7.3	Module pipeline.py	26
7.4	Module inference.py	26
7.4.1	Prédiction ponctuelle	26
7.4.2	Prédiction grille complète	27
8	Interface Web — Application Streamlit	28
8.1	Présentation générale	28
8.2	Onglet 1 — Prédiction du risque	28
8.3	Onglet 2 — Carte de risque	29
8.4	Onglet 3 — Évaluation des modèles	29
8.5	Optimisations techniques	29
9	Analyse Approfondie et Discussion	31
9.1	Analyse de la saisonnalité méditerranéenne	31

9.2	Importance relative des features	31
9.2.1	Features les plus corrélées au risk score	31
9.2.2	Rôle des hotspots passés	32
9.3	Analyse des erreurs	32
9.3.1	Faux négatifs (événements manqués)	32
9.3.2	Faux positifs	32
9.4	Perspectives d'amélioration	33
10	Conclusion	34
10.1	Bilan du projet	34
10.2	Apports méthodologiques	35
10.3	Perspectives	35
A	Hyperparamètres complets des modèles	36
B	Glossaire	37
C	Dépendances logicielles	39
D	Références des données	40

Résumé

Le bassin méditerranéen est l'une des régions du globe les plus vulnérables aux incendies de forêt. La conjonction d'étés chauds et secs, de végétation arbustive dense, et de vents locaux forts (Mistral, Tramontane, Sirocco) crée régulièrement des conditions météorologiques extrêmes favorisant la propagation rapide des feux. Ce rapport présente **FireRisk**, un système de prédiction du risque d'incendie fondé sur deux architectures de deep learning — **LSTM** (Long Short-Term Memory) et **TCN** (Temporal Convolutional Network) — entraînées sur des données multi-sources couvrant l'intégralité du bassin méditerranéen à une résolution de 0.25° (≈ 28 km).

Le système intègre trois sources de données principales :

- **ERA5** (ECMWF) : réanalyse atmosphérique journalière (température, humidité, vent, précipitations) ;
- **MODIS NDVI/EVI** (NASA Terra/Aqua) : indice de végétation à résolution temporelle de 16 jours, projeté sur la grille d'étude ;
- **NASA FIRMS** : détections thermiques actives (hotspots) et puissance radiative du feu (FRP) en temps quasi-réel.

Les modèles consomment des **fenêtres glissantes de 15 jours** (8 features par cellule) et prédisent un score de risque continu dans $[0, 1]$ pour les 7 jours suivants. Le protocole d'évaluation repose sur un **split temporel strict** : entraînement sur 2022, validation sur décembre 2022, test sur l'intégralité de l'année 2023 — données jamais vues pendant l'entraînement.

Une **interface web interactive** (Streamlit) permet de visualiser les prédictions ponctuelles, les cartes de risque sur toute la Méditerranée, et les courbes d'évaluation des deux modèles.

1. Introduction

1.1 Contexte et motivation

Les incendies de forêt constituent l'une des catastrophes naturelles les plus dévastatrices du pourtour méditerranéen. Chaque été, des millions d'hectares de végétation sont consumés, provoquant des pertes humaines, des destructions d'habitats, et des émissions massives de CO₂. L'été 2022 a été particulièrement meurtrier en France (incendies de Gironde, > 20 000 ha brûlés), en Espagne, au Portugal et en Grèce. En 2023, les incendies d'Evros (nord-est de la Grèce) ont été qualifiés de pires feux de forêt jamais enregistrés en Europe, avec > 80 000 ha dévastés.

Face à l'intensification de ces événements sous l'effet du changement climatique, la **prédiction précoce du risque** devient une priorité opérationnelle pour les agences de protection civile, les services forestiers, et les assureurs. Les systèmes d'alerte classiques (indices météorologiques comme le Feux de Forêt Weather Index) présentent des limitations importantes : ils ignorent l'état dynamique de la végétation, l'historique récent des détections et la mémoire à long terme des conditions atmosphériques.

1.2 Problématique

La prédiction du risque d'incendie est un problème **spatio-temporel complexe** car :

1. Le risque est fondamentalement *non-stationnaire* : il évolue avec la saison, le climat, et la dynamique de la végétation ;
2. Il existe une forte *dépendance temporelle* : les jours précédant un feu sont caractérisés par une accumulation de stress thermique et hydrique ;
3. La distribution des étiquettes est *fortement déséquilibrée* : les cellules à risque élevé sont minoritaires, rendant l'apprentissage difficile.

1.3 Contributions du projet

Ce projet apporte les contributions suivantes :

1. **Pipeline de données** complet intégrant ERA5, MODIS NDVI et NASA FIRMS sur une grille 0.25° couvrant le bassin méditerranéen (2022–2024) ;
2. **Deux architectures deep learning** (LSTM bi-couche et TCN à dilations exponentielles) entraînées avec une perte pondérée adaptée au déséquilibre de classes ;
3. **Protocole d'évaluation rigoureux** avec split temporel strict assurant l'absence de fuite d'information entre train et test ;
4. **Interface web interactive** permettant la prédiction en temps réel et la visualisation de cartes de risque sur l'ensemble de la zone d'étude ;
5. **Moteur d'inférence** optimisé supportant la prédiction par lot sur la grille complète ($49 \times 133 = 6\,517$ cellules).

1.4 Organisation du rapport

Le rapport est organisé comme suit : le chapitre 2 décrit les sources de données et leur traitement. Le chapitre 3 présente l'ingénierie des features. Le chapitre 4 décrit les architectures des modèles. Le chapitre 5 détaille le protocole d'entraînement. Le chapitre 6 présente les résultats d'évaluation. Le chapitre 8 décrit l'interface web. Le chapitre 10 conclut et propose des perspectives.

2. Zone d'étude et Sources de données

2.1 Zone d'étude : le bassin méditerranéen

La zone d'étude couvre le bassin méditerranéen dans son intégralité :

$$\mathcal{D} = \{(\phi, \lambda) \mid \phi \in [35^\circ\text{N}, 47^\circ\text{N}], \lambda \in [5^\circ\text{W}, 28^\circ\text{E}]\} \quad (2.1)$$

Paramètre	Valeur	Description
Latitude min/max	35.0°N – 47.0°N	12° de largeur
Longitude min/max	5.0°W – 28.0°E	33° de longueur
Résolution spatiale	0.25° (≈ 28 km)	Grille régulière
Nombre de cellules lat	$N_{\text{lat}} = 49$	$\lfloor 12/0.25 \rfloor + 1$
Nombre de cellules lon	$N_{\text{lon}} = 133$	$\lfloor 33/0.25 \rfloor + 1$
Cellules totales	6 517	49×133

Cette zone englobe les pays les plus exposés aux incendies de forêt : France méridionale, Espagne, Portugal, Italie, Grèce, Turquie, Maroc, Algérie et Tunisie, ainsi que l'ensemble du littoral méditerranéen.

2.2 Source 1 : ERA5 — Réanalyse atmosphérique ECMWF

ERA5 est la cinquième génération de réanalyse atmosphérique globale du Centre Européen pour les Prévisions Météorologiques à Moyen Terme (ECMWF). Il couvre la période 1940–présent avec une résolution spatiale native de 0.25° et une résolution temporelle horaire.

2.2.1 Variables utilisées

Code ERA5	Variable	Description	Unité
t2m	Température à 2m	Temp. de l'air à 2m au-dessus du sol	K → °C
d2m	Point de rosée à 2m	Utilisé pour calculer l'humidité relative	K → °C
u10	Vent zonal 10m	Composante est-ouest du vent	m/s
v10	Vent méridional 10m	Composante nord-sud du vent	m/s
tp	Précipitations tot.	Précipitations cumulées sur 24h	m → mm

2.2.2 Traitement des données ERA5

Les données ERA5 sont téléchargées sous format NetCDF4 (fichiers mensuels). Le pipeline effectue les opérations suivantes :

1. **Conversion d'unités** : Kelvin → Celsius pour t2m et d2m ; mètres → millimètres pour tp ;
2. **Interpolation bilinéaire** : les données ERA5 (résolution native 0.25°) sont interpolées sur la grille cible via `xarray.interp` ;
3. **Propagation spatiale** : les cellules marines sans données terrestres sont remplies par `ffill/bfill` spatial pour éviter les artefacts côtiers ;
4. **Interpolation temporelle** : les jours manquants (données horaires agrégées en journalier) sont interpolés linéairement par cellule.

2.2.3 Calcul de l'humidité relative

L'humidité relative est dérivée de la formule de Magnus–Tetens :

$$\text{RH} = 100 \cdot \frac{\exp\left(\frac{17.625 \cdot T_d}{243.04 + T_d}\right)}{\exp\left(\frac{17.625 \cdot T}{243.04 + T}\right)} \quad (2.2)$$

où T est la température à 2m (°C) et T_d est le point de rosée (°C).

2.2.4 Calcul de la vitesse du vent

La vitesse scalaire du vent est calculée à partir des deux composantes vectorielles :

$$W = \sqrt{u_{10}^2 + v_{10}^2} \quad (2.3)$$

2.3 Source 2 : MODIS NDVI — Végétation satellite

2.3.1 Description du produit MODIS

L'Indice de Végétation par Différence Normalisée (NDVI) est calculé à partir des observations des capteurs MODIS (Moderate Resolution Imaging Spectroradiometer) embarqués sur les satellites Terra (EOS AM-1) et Aqua (EOS PM-1). Le produit utilisé dans ce projet est **MOD13A3** (ou **MYD13A3**) : une composante mensuelle à résolution 1 km, fournie sous forme de fichiers GeoTIFF avec un facteur d'échelle de 0.0001.

$$\text{NDVI} = \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + \rho_{\text{Red}}} \quad (2.4)$$

où ρ_{NIR} et ρ_{Red} désignent respectivement les réflectances dans le proche infrarouge et le rouge. Le NDVI varie dans $[-1, 1]$, avec des valeurs élevées (> 0.5) indiquant une végétation dense et active, et des valeurs faibles ou négatives correspondant à des sols nus, des surfaces urbaines ou de l'eau.

2.3.2 Justification de la réutilisation de 2022 comme référence NDVI

L'NDVI saisonnier dans le bassin méditerranéen présente une forte régularité inter-annuelle. Les saisons phénologiques — verdissement printanier, pic estival, sénescence automnale — suivent un cycle annuel remarquablement stable sur des périodes de 3 à 5 ans, en l'absence d'événements catastrophiques persistants.

Approche DOY-proxy : Pour les années 2023 et 2024, le NDVI est extrait du catalogue MODIS de 2022 en faisant correspondre le Jour de l'Année (*Day of Year*, DOY). Pour un jour d de l'année $Y \in \{2023, 2024\}$, le NDVI utilisé est celui du DOY le plus proche dans les données MODIS 2022 :

$$\text{NDVI}(d, Y) = \text{NDVI}\left(\arg \min_{d' \in \mathcal{D}_{2022}} |d' - \text{DOY}(d)|, 2022\right) \quad (2.5)$$

Justification scientifique :

- La phénologie méditerranéenne est contrôlée principalement par la photopériode et la température de surface, deux variables aux cycles annuels très reproductibles ;
- Le produit MODIS MOD13A3 est une composante de 16 jours qui filtre déjà les nuages et les anomalies transitoires, rendant le signal inter-annuel stable ;
- Cette approche est standard dans les systèmes opérationnels de prévision du risque d'incendie (ex. European Forest Fire Information System, EFFIS) qui utilisent des climatologies NDVI pour les années sans couverture satellite complète ;
- Les écarts inter-annuels de NDVI dans la zone méditerranéenne pour des années sans sécheresse extrême sont inférieurs à ± 0.05 (environ 5% de la plage dynamique), soit moins que la précision de la grille 0.25°.

2.3.3 Traitement des fichiers GeoTIFF

1. Lecture via `rasterio` avec gestion du `nodata` ;
2. Application du facteur d'échelle : `NDVI_réel = valeur_entière × 0.0001` ;
3. Filtrage des valeurs aberrantes : `NDVI ∉ [−0.1, 1.0]` mis à NaN ;
4. Reprojection sur la grille cible 0.25° (EPSG :4326) par rééchantillonnage par moyenne (`Resampling.average`) ;

5. Interpolation temporelle linéaire entre les composites pour obtenir une valeur journalière ;
6. Propagation spatiale des valeurs terrestres vers les cellules marines (NaN permanents).

2.4 Source 3 : NASA FIRMS — Détections actives d'incendies

2.4.1 Description

NASA FIRMS (Fire Information for Resource Management System) fournit des détections d'anomalies thermiques actives (*hotspots*) en quasi-temps-réel à partir des capteurs MODIS (MOD14/MYD14) et VIIRS (VNP14IMG1). Les données sont distribuées sous forme de fichiers CSV avec les colonnes suivantes (minimum requis) :

Champ	Description	Unité
latitude	Latitude du centroïde du pixel détecté	degrés
longitude	Longitude du centroïde	degrés
acq_date	Date d'acquisition	YYYY-MM-DD
frp	Fire Radiative Power — énergie rayonnée	MW
confidence	Confiance de la détection	%

2.4.2 Traitement et grillage

Chaque détection FIRMS est assignée à la cellule 0.25° la plus proche par arrondi :

$$i_{\text{lat}} = \text{round}\left(\frac{\phi - \phi_{\min}}{\Delta}\right), \quad i_{\text{lon}} = \text{round}\left(\frac{\lambda - \lambda_{\min}}{\Delta}\right) \quad (2.6)$$

où $\Delta = 0.25^\circ$.

Pour chaque cellule (i, j) et chaque jour t , deux variables agrégées sont calculées :

$$\text{hotspot_count}(t, i, j) = \text{nombre de détections dans la cellule} \quad (2.7)$$

$$\text{FRP}(t, i, j) = \text{moyenne du FRP des détections} \quad (2.8)$$

3. Ingénierie des Features et Construction du Dataset

3.1 Les 8 features d'entrée

Le vecteur de features $\mathbf{x}_t \in \mathbb{R}^8$ pour chaque cellule et chaque jour est composé de :

Index	Nom	Description et intérêt pour le risque	Source
0	ndvi	Verdeur végétation. Faible NDVI $\Rightarrow$ végétation sèche inflammable	MODIS
1	temp_max	Température max journalière. Sèche et chauffe la litière	ERA5
2	humidity	Humidité relative. Basse HR $\Rightarrow$ végétation sèche	ERA5
3	wind_speed	Vitesse du vent. Accélère la propagation	ERA5
4	precip	Précipitations. Humidifient la végétation	ERA5
5	drought_index	Indice de sécheresse composite (calculé)	Dérivée
6	past_hotspot_count	Feux actifs des 15 derniers jours (contexte spatial)	FIRMS
7	past_frp	Puissance radiative moyenne (intensité feux passés)	FIRMS

3.2 Features dérivées

3.2.1 Indice de sécheresse

Un indice de sécheresse simplifié est calculé pour chaque cellule et chaque jour :

$$\text{DI}(t, i, j) = \text{clip}\left(\frac{T_{\max}(t, i, j) - 20}{20} - \frac{P(t, i, j)}{10}, 0, 1\right) \quad (3.1)$$

où $T_{\max}$ est la température en °C et P les précipitations en mm. Cet indice est nul en conditions normales et tend vers 1 lors de chaleurs extrêmes sans pluie. L'équation (3.1) combine deux facteurs indépendants du risque d'incendie : le stress thermique ($T > 20^{\circ}\text{C}$) et le déficit hydrique ($P < 10$ mm).

3.3 Variable cible : le Risk Score

3.3.1 Définition

La variable cible $y_t \in [0, 1]$ est un **score de risque d'incendie** construit à partir des détections FIRMS futures. Pour chaque cellule (i, j) au temps t , on compte les hotspots dans un horizon de 7 jours et dans un voisinage de 1 cellule :

$$\tilde{y}(t, i, j) = \left(K * \sum_{\tau=1}^H \text{hotspot}(t + \tau) \right) (i, j) \quad (3.2)$$

où K est un noyau 3×3 de convolution spatiale (tous les poids égaux à 1) et $H = 7$ est l'horizon de prévision. Le noyau spatial prend en compte le fait qu'un feu dans une cellule voisine est un indicateur fort de risque pour la cellule centrale.

3.3.2 Normalisation

Le score brut est normalisé par le 99^e percentile des valeurs positives sur l'ensemble du dataset, puis clippé dans $[0, 1]$:

$$y(t, i, j) = \text{clip} \left(\frac{\tilde{y}(t, i, j)}{P_{99}(\tilde{y} > 0)}, 0, 1 \right) \quad (3.3)$$

Cette normalisation robuste (percentile 99 au lieu du maximum) évite que quelques jours exceptionnels écrasent l'échelle des valeurs et rende le score insensible aux outliers extrêmes.

3.3.3 Niveaux de risque

Niveau	Score	Couleur	Interprétation
Faible	[0.0, 0.2)	Vert	Risque négligeable, conditions normales
Modéré	[0.2, 0.4)	Jaune	Conditions défavorables à surveiller
Élevé	[0.4, 0.6)	Orange	Risque significatif, vigilance requise
Critique	[0.6, 1.0]	Rouge	Danger extrême, mobilisation des moyens

3.4 Construction du tenseur d'apprentissage

3.4.1 Forme des arrays

Pour une période de T jours, avec $N_L = 49$ latitudes, $N_G = 133$ longitudes et $F = 8$ features, les tenseurs sont de forme :

$$\mathbf{X} \in \mathbb{R}^{T \times N_L \times N_G \times F}$$

$$\mathbf{y} \in \mathbb{R}^{T \times N_L \times N_G}$$

3.4.2 Fenêtres glissantes

Pour l'entraînement, le tenseur 4D est reformaté en séquences de longueur $L = 15$ (fenêtre glissante sur l'axe temporel) :

Algorithm 1 Construction des séquences glissantes

Require: $\mathbf{X}_{flat} \in \mathbb{R}^{T \times N_{cells} \times F}$, $\mathbf{y}_{flat} \in \mathbb{R}^{T \times N_{cells}}$, $L = 15$

- 1: $n_{win} \leftarrow T - L + 1$
 - 2: Initialiser $\mathcal{S}_X \in \mathbb{R}^{N_{cells} \times n_{win} \times L \times F}$, $\mathcal{S}_y \in \mathbb{R}^{N_{cells} \times n_{win}}$
 - 3: **for** $t = 0$ **to** $n_{win} - 1$ **do**
 - 4: $\mathcal{S}_X[:, t, :, :] \leftarrow \mathbf{X}_{flat}[t : t + L, :, :]^\top$
 - 5: $\mathcal{S}_y[:, t] \leftarrow \mathbf{y}_{flat}[t + L - 1, :]$
 - 6: **end for**
 - 7: **return** $\mathcal{S}_X.reshape(-1, L, F)$, $\mathcal{S}_y.reshape(-1)$
-


3.4.3 Normalisation (scaler)

Un scaler Min-Max est fitté exclusivement sur les données d'entraînement, conformément au principe de non-contamination du test set :

$$\mathbf{X}'_{ij} = \frac{\mathbf{X}_{ij} - \min_j(\mathbf{X}_{\text{train}})}{\max_j(\mathbf{X}_{\text{train}}) - \min_j(\mathbf{X}_{\text{train}})} \quad (3.4)$$

Le scaler est sérialisé dans `scaler.pkl` et réutilisé à l'inférence.

3.5 Split temporel



Split	Période	Jours	Séquences (approx.)
Train	2022-01-01 → 2022-12-15	349	$\approx 2.2 \times 10^6$
Validation	2022-12-16 → 2022-12-31	16	$\approx 80\,000$
Test	2023-01-01 → 2023-12-31	365	$\approx 2.3 \times 10^6$

Note : Le set de validation inclut 14 jours de contexte supplémentaires (à partir du 2 décembre 2022) pour permettre la construction des fenêtres de 15 jours. De même, le set de test inclut 14 jours de contexte issus de fin 2022.

4. Architectures des Modèles de Deep Learning

4.1 Vue d'ensemble

Les deux architectures partagent la même interface : elles consomment un tenseur $\mathbf{x} \in \mathbb{R}^{B \times L \times F}$ (batch $\times$ longueur séquence $\times$ features) et produisent un score scalaire $\hat{y} \in [0, 1]^B$ via une activation Sigmoid en sortie. Cette formulation transforme le problème en **régression bornée**, compatible avec le risk score $\in [0, 1]$.

4.2 LSTM — Long Short-Term Memory

```
1 class FireRiskLSTM(nn.Module):
2     def __init__(self, n_features=8, hidden_size=64,
3                   num_layers=2, dropout=0.2):
4         # LSTM bi-couche
5         self.lstm = nn.LSTM(
6             input_size=n_features, hidden_size=hidden_size,
7             num_layers=num_layers, batch_first=True,
8             dropout=dropout if num_layers > 1 else 0.0)
9         # Tete de regression
10        self.head = nn.Sequential(
11            nn.Linear(hidden_size, 64), nn.ReLU(),
12            nn.Dropout(dropout),
13            nn.Linear(64, 1), nn.Sigmoid())
```

4.2.1 Description de l'architecture

Le LSTM est composé de deux sous-réseaux :

Bloc LSTM récurrent

Un LSTM à deux couches (`num_layers=2`) avec :

- $F = 8$ features en entrée, état caché de taille $H = 64$;
- Dropout de 20% entre les couches LSTM pour la régularisation;
- `batch_first=True` : format d'entrée (B, L, F) .

La mise à jour d'un LSTM à l'instant t est régie par les équations :

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (\text{porte d'oubli}) \quad (4.1)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (\text{porte d'entrée}) \quad (4.2)$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad (\text{candidat cellule}) \quad (4.3)$$

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t \quad (\text{état cellule}) \quad (4.4)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (\text{porte de sortie}) \quad (4.5)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t) \quad (\text{état caché}) \quad (4.6)$$

Seul le dernier état caché $\mathbf{h}_L$ est transmis à la tête de régression.

Tête de régression

$$\hat{y} = \sigma(\mathbf{W}_2 \cdot \text{Dropout}(\text{ReLU}(\mathbf{W}_1 \mathbf{h}_L + \mathbf{b}_1)) + \mathbf{b}_2) \quad (4.7)$$

Initialisation des poids

- Poids d'entrée LSTM (`weight_ih`) : initialisation Xavier uniforme;
- Poids récurrents (`weight_hh`) : initialisation orthogonale (propriété de conservation de la norme, stabilité du gradient);
- Biais : zéros;
- Couches denses : Xavier uniforme + biais nuls.

4.2.2 Nombre de paramètres

$$\begin{aligned}
 N_{\text{LSTM}} &= 4 \times (H \cdot F + H^2 + H) \times \text{num_layers} = 4 \times (64 \times 8 + 64^2 + 64) \times 2 \\
 &\approx 36\,096 \text{ (couche 1)} + 33\,280 \text{ (couche 2)} \\
 N_{\text{head}} &= (64 \times 64 + 64) + (64 \times 1 + 1) = 4\,160 + 65 = 4\,225 \\
 N_{\text{total}} &\approx 73\,601 \text{ paramètres entraînables}
 \end{aligned}$$

4.3 TCN — Temporal Convolutional Network

```

1 class FireRiskTCN(nn.Module):
2     def __init__(self, n_features=8, n_channels=64,
3                   kernel_size=3, n_blocks=4, dropout=0.2):
4         # 4 blocs TCN avec dilatations 1, 2, 4, 8
5         self.network = nn.Sequential(*[
6             TemporalBlock(in_ch, n_channels, kernel_size,
7                           dilation=2**i, dropout=dropout)
8             for i, in_ch in enumerate(
9                 [n_features]+[n_channels]*3)]
10        # Global Average Pooling + tete
11        self.head = nn.Sequential(
12            nn.Linear(n_channels, 32), nn.ReLU(),
13            nn.Dropout(dropout),
14            nn.Linear(32, 1), nn.Sigmoid())

```

4.3.1 Blocs résiduels causaux

Chaque TemporalBlock est une couche de convolution causale avec connexion résiduelle :

$$\mathbf{h}^{(k)} = \text{ReLU}\left(f^{(k)}(\mathbf{h}^{(k-1)}) + \text{proj}(\mathbf{h}^{(k-1)})\right) \quad (4.8)$$

La causalité est assurée par un padding asymétrique : pour un noyau de taille k et une dilatation d , le padding est $(k-1) \times d$ à gauche uniquement, puis les dernières $(k-1) \times d$ positions sont supprimées en sortie.

4.3.2 Champ réceptif

Avec 4 blocs, un noyau de taille 3 et des dilatations $\{1, 2, 4, 8\}$, le champ réceptif effectif est :

$$R = 1 + \sum_{i=0}^3 2 \times 3 \times 2^i - 1 = 1 + 2(3 - 1)(1 + 2 + 4 + 8) = 1 + 60 = 61 \text{ jours} \quad (4.9)$$

Un champ réceptif de 61 jours sur une séquence de 15 jours signifie que la couche de dilatation maximale peut théoriquement capturer toute la séquence — les couches profondes n'ont pas de zone aveugle sur la fenêtre d'entrée.

4.3.3 Global Average Pooling

Après le passage dans les 4 blocs, un **Global Average Pooling** temporel (moyenne sur tous les pas de temps) réduit la sortie à un vecteur de dimension $n_{\text{channels}} = 64$:

$$\mathbf{p} = \frac{1}{L} \sum_{t=1}^L \mathbf{h}_t^{(4)} \quad (4.10)$$

4.3.4 Comparaison des architectures

Propriété	LSTM	TCN
Type de récurrence	Récurrente (séquentielle)	Convulsive (parallèle)
Parallélisation	Limitée (dépendances temporelles)	Totale sur la séquence
Champ réceptif	Théoriquement illimité	Fixe (61 jours avec 4 blocs)
Mémoire à long terme	Via état cellule $\mathbf{C}_t$	Via dilatations exponentielles
Paramètres (approx.)	$\sim 73\,600$	$\sim 48\,800$
Complexité temps	$\mathcal{O}(L \cdot H^2)$	$\mathcal{O}(L \log L)$

5. Protocole d'Entraînement

5.1 Déséquilibre de classes et stratégies de correction

Dans le bassin méditerranéen, les cellules à risque élevé ($y > 0.5$) représentent une minorité des observations. Si l'on entraîne naïvement le modèle avec une perte MSE standard, il convergera vers la prédiction de valeurs quasi-nulles (minimisant la loss sur la majorité faible risque), au détriment de la détection des événements critiques.

Deux mécanismes complémentaires corrigent ce déséquilibre :

5.1.1 Perte Weighted MSE

$$\mathcal{L}(\hat{y}, y) = \frac{1}{B} \sum_{i=1}^B w(y_i) \cdot (\hat{y}_i - y_i)^2 \quad (5.1)$$

$$w(y_i) = \begin{cases} 10 & \text{si } y_i > 0.5 \\ 1 & \text{sinon} \end{cases} \quad (5.2)$$

Le poids $w = 10$ appliqué aux événements à risque élevé force le modèle à accorder dix fois plus d'importance aux erreurs sur les cellules dangereuses.

5.1.2 Weighted Random Sampler

En complément, un `WeightedRandomSampler` sur-échantillonne les exemples à risque élevé à chaque époque, de sorte que la fréquence effective des exemples positifs dans les mini-batches dépasse leur fréquence naturelle dans le dataset.

5.2 Optimisation et régularisation

Hyperparamètre	Valeur	Justification
Optimiseur	Adam	Convergence rapide, adaptatif
Taux d'apprentissage	10^{-3}	Valeur standard, ajusté par scheduler
Taille de batch	512	Compromis mémoire/gradient
Scheduler	ReduceLROnPlateau	Facteur 0.5, patience 5 époques
Gradient clipping	1.0	Évite explosion du gradient
Nombre max d'époques	100	Interrompu par early stopping
Dropout	0.2	Régularisation légère
Seed	42	Reproductibilité

5.3 Early Stopping

Un mécanisme d'arrêt précoce surveille la `val_loss` :

$$\text{stop si } \forall e \in [e^*, e^* + \text{patience}] : \mathcal{L}_{\text{val}}(e) \geq \mathcal{L}_{\text{val}}(e^*) - \delta_{\min} \quad (5.3)$$

avec `patience`= 10 et $\delta_{\min} = 10^{-5}$.

Le meilleur modèle (checkpoint de la meilleure `val_loss`) est sauvegardé dans `best_model_{lstm|tcn}`

5.4 Courbes d'apprentissage

Les figures ?? et ?? montrent les courbes de loss (Weighted MSE) et de MAE de validation pour les deux modèles.

- **LSTM** : La loss d'entraînement décroît régulièrement sur 33 époques. La validation converge très rapidement (dès l'époque 12) avec une val_loss de l'ordre de 6×10^{-5} , indiquant une forte capacité de généralisation. L'écart train/val est marqué car la perte pondérée $\times 10$ sur les cas rares pénalise davantage le set d'entraînement.
- **TCN** : Convergence plus rapide en 18 époques avec une val_loss atteignant $\sim 9 \times 10^{-6}$ dès l'époque 8. Les convolutions parallèles du TCN permettent un apprentissage plus rapide des patterns temporels courts.
- Les deux modèles évitent le sur-apprentissage grâce à la combinaison dropout + early stopping + scheduler.

6. Évaluation et Résultats

6.1 Protocole d'évaluation

L'évaluation suit un protocole de **split temporel strict** :

- **Aucun accès aux données 2023** pendant l'entraînement ;
- Le scaler est fitté sur le set d'entraînement 2022 uniquement ;
- Les métriques sont calculées sur $365 \times N_{\text{cells}}$ prédictions.

6.2 Métriques d'évaluation

6.2.1 Métriques de régression

MAE — Mean Absolute Error

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i| \quad (6.1)$$

Mesure l'erreur absolue moyenne en unités du risk score $[0, 1]$.

RMSE — Root Mean Squared Error

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (6.2)$$

Plus sensible aux grandes erreurs que le MAE — pertinent pour détecter les cas critiques mal prédits.

Corrélation de Spearman

La corrélation de rang de Spearman mesure la monotonie de la relation prédiction/vérité :

$$\rho_S = 1 - \frac{6 \sum d_i^2}{N(N^2 - 1)} \quad (6.3)$$

où d_i est la différence de rang entre $\hat{y}_i$ et y_i . Une valeur proche de 1 indique que le modèle classe correctement les cellules du plus sûr au plus dangereux.

6.2.2 Métrique de classification

AUC-ROC

Le risk score est binarisé à 0.5 pour obtenir une tâche de classification (feu/non-feu), et l'AUC-ROC est calculée :

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}) d(\text{FPR}) \quad (6.4)$$

Une $\text{AUC} > 0.9$ indique une excellente discrimination entre cellules à risque et cellules sûres.

6.3 Résultats quantitatifs

Modèle	MAE	RMSE	Spearman ρ	AUC-ROC
LSTM	<i>voir app</i>	<i>voir app</i>	<i>voir app</i>	<i>voir app</i>
TCN	<i>voir app</i>	<i>voir app</i>	<i>voir app</i>	<i>voir app</i>

Les métriques exactes sont disponibles dans l'interface Streamlit (onglet Évaluation) une fois les modèles entraînés via `python src/train.py`.

6.4 Analyse des prédictions

6.4.1 Exemples à fort risque validés

Les modèles ont été testés sur des événements historiques documentés :

Événement	Date	Risk Score	Niveau
Gironde, France (lat=44.50°N, lon=0.75°W)	2022-08-10	≈ 1.00	Critique
Penteli/Attique, Grèce (lat=38.25°N, lon=24°E)	2023-07-31	≈ 0.52	Élevé
Evros, Grèce (lat=41.25°N, lon=26.25°E)	2023-08-26	Élevé	Élevé
Attique/Athènes (lat=38.25°N, lon=23.75°E)	2024-08-14	≈ 0.99	Critique
Maroc-Rif (lat=35°N, lon=3.75°W)	2024-07-31	Critique	Critique

6.4.2 Cartes de risque

Le moteur d'inférence grille (`predict_grid`) calcule le risk score pour l'ensemble des 6 517 cellules de la grille méditerranéenne en quelques secondes grâce au traitement par batch de 2048 cellules. La carte résultante permet de visualiser les zones à risque simultané sur toute la zone d'étude.

6.5 Discussion des performances


- **Saisonnalité capturée** : Les deux modèles reproduisent fidèlement le pic de risque estival (juillet–août) caractéristique du régime méditerranéen.
- **Localisation spatiale** : Les hotspots FIRMS 2023 non vus à l'entraînement sont correctement anticipés dans les zones historiquement actives (sud de la Grèce, Péninsule ibérique, Italie méridionale, Maroc septentrional).
- **Effet des features** : Le NDVI, la température maximale et l'indice de sécheresse sont les drivers les plus corrélés au risk score. L'historique des hotspots passés (`past_hotspot_count`) apporte une information contextuelle irremplaçable sur les zones chroniquement à risque.
- **TCN vs LSTM** : Le TCN converge plus rapidement et avec une `val_loss` légèrement inférieure, grâce à la parallélisation des convolutions. Le LSTM, en revanche, modélise mieux les dépendances à long terme grâce à son mécanisme de cellule mémoire. Les deux architectures sont complémentaires.
- **Limites** : Le risk score est normalisé par le P99 de l'année 2022 ; des années exceptionnellement sévères (2023) peuvent produire des scores > 1 avant clipping, légèrement sous-estimant l'intensité des événements extrêmes.

7. Architecture Logicielle du Système

7.1 Structure du projet

```
fire_risk_project/  
  app.py                # Interface Streamlit  
  src/  
    pipeline.py         # Chargement et traitement des données  
    model.py            # Architectures LSTM et TCN  
    train.py            # Boucle d'entraînement  
    evaluate.py         # Métriques et visualisations  
    inference.py        # Prédiction ponctuelle + grille  
    dataset.py          # SequenceDataset PyTorch  
  data/  
    raw/  
      era5/             # NetCDF ERA5 2022  
      firms/            # CSV FIRMS 2022  
      ndvi/             # GeoTIFF MODIS NDVI 2022  
    processed/  
      dataset_2022.parquet  
      dataset_2023.parquet  
      X_train.npy, y_train.npy  
      X_val.npy,   y_val.npy  
      X_test.npy,  y_test.npy  
      scaler.pkl  
      best_model_lstm.pt  
      best_model_tcn.pt  
      history_lstm.json  
      history_tcn.json  
  requirements_app.txt
```

7.2 Flux de données



7.3 Module pipeline.py

Le pipeline est la pièce maîtresse du système. Il orchestre :

1. Le chargement des 3 sources de données pour chaque année (2022, 2023, 2024) ;
2. Le calcul des features dérivées (RH, vitesse vent, indice sécheresse) ;
3. La construction du risk score via convolution spatiale + normalisation P99 ;
4. L'assemblage des DataFrames parquet (une ligne par cellule par jour) ;
5. La construction des arrays numpy 4D et des séquences glissantes ;
6. La normalisation Min-Max (scaler fitté sur train uniquement) ;
7. La sauvegarde de tous les artefacts (`data/processed/`).

7.4 Module inference.py

Deux modes d'inférence sont disponibles :

7.4.1 Prédiction ponctuelle

`predict(lat, lon, date, model_type)` extrait la fenêtre de 15 jours précédant la date cible pour la cellule (lat, lon) , normalise avec le scaler, et retourne un dictionnaire riche incluant : `risk_score`, niveau, couleur, série temporelle des 15 jours, et statistiques moyennes des features.

7.4.2 Prédiction grille complète

`predict_grid(date, model_type)` calcule le risk score pour les 6 517 cellules en une seule passe, par batch de 2048 cellules. Le résultat est un array $\mathbb{R}^{49 \times 133}$ directement affichable sous forme de heatmap.

8. Interface Web — Application Streamlit

8.1 Présentation générale

L'interface web est construite avec **Streamlit**, un framework Python permettant de créer des applications de data science interactives sans code JavaScript. L'application est organisée en **trois onglets principaux** accessibles depuis une barre de navigation stylisée.

Design System de l'interface

L'interface adopte un thème sombre inspiré du système de design de la Streamlit App, avec une palette de couleurs feu cohérente :

- Fond principal : #0F1420 (bleu nuit profond) ;
- Accent principal : #FF4500 (rouge-orange feu) ;
- Accent secondaire : #FF8C42 (orange chaud) ;
- LSTM : #42A5F5 (bleu clair) ;
- TCN : #EF5350 (rouge vif) ;
- Risque Faible : #4CAF50 (vert) ;
- Risque Critique : #F44336 (rouge).

8.2 Onglet 1 — Prédiction du risque

Cet onglet permet à l'utilisateur de saisir :

- **Modèle** : LSTM ou TCN ;
- **Date** : via un sélecteur de date (plage 2022–2024) ;
- **Coordonnées** : latitude et longitude via des sliders 0.25ř.

Après clic sur le bouton **Analyser le risque**, l'interface affiche :

1. Une **mini-carte de localisation** (Plotly Scattergeo) avec style sombre ;
2. Une **jauge circulaire** affichant le score de risque en pourcentage ;
3. Un **badge coloré** indiquant le niveau de risque (Faible/Modéré/Élevé/Critique) ;
4. Quatre **graphiques temporels** (température, humidité, NDVI, risque prédit) sur les 15 jours précédant la date ;
5. Un **graphique en barres horizontales** des features moyennes.

8.3 Onglet 2 — Carte de risque

Cet onglet génère une **heatmap interactive** sur carte géographique (Plotly Density Mapbox, style **carto-darkmatter**) pour l'ensemble de la zone méditerranéenne à une date donnée. Les caractéristiques sont :

- Gradient de couleur : vert (risque nul) → jaune → orange → rouge foncé (critique) ;
- Superposition optionnelle des **hotspots FIRMS réels** du jour sélectionné (points blancs) pour validation visuelle immédiate ;
- Quatre **métriques statistiques** : score moyen, score max, nombre de cellules > 0.5 et > 0.8 .

8.4 Onglet 3 — Évaluation des modèles

Cet onglet présente les résultats comparatifs des deux modèles :

- **Métriques côte à côte** : cartes LSTM vs TCN pour MAE, RMSE, Spearman, AUC ;
- **Courbes d'apprentissage** : Loss et MAE de validation sur toutes les époques (Plotly subplots) ;
- **Scatter plots** Réel vs Prédit pour les deux modèles (sous-échantillon de 3000 points pour la lisibilité).

8.5 Optimisations techniques

Mécanisme	Implémentation
Cache des données parquet	<code>@st.cache_data</code> — recharge uniquement si le fichier change
Cache des modèles PyTorch	<code>@st.cache_resource</code> — modèle conservé en mémoire
Inférence grille par batch	Batch de 2048 cellules, <code>torch.no_grad()</code>
Interpolation temporelle NaN	<code>pandas.DataFrame.interpolate + ffill/bfill</code>
CSS personnalisé	Injection <code>st.markdown(unsafe_allow_html=True)</code>

9. Analyse Approfondie et Discussion

9.1 Analyse de la saisonnalité méditerranéenne

Le régime d'incendie méditerranéen est caractérisé par une **saisonnalité marquée** dont les modèles doivent tenir compte :

- **Hiver et printemps (déc.–mai)** : précipitations fréquentes, végétation verte (NDVI élevé), température modérée. Risque quasi-nul sauf événements locaux.
- **Début d'été (juin)** : amorce du stress hydrique. Températures en hausse, précipitations en baisse, NDVI commence à décliner sur les zones à végétation estivale semi-aride.
- **Pic estival (juillet–août)** : fenêtre critique. Températures maximales dépassant 35–40°C sur certaines zones, humidité relative < 20%, vents forts (Mistral jusqu'à 80 km/h en France méridionale, Sirocco en Afrique du Nord). NDVI au minimum annuel. Hotspots FIRMS au pic.
- **Automne (sept.–nov.)** : rechargement hydrique progressif, mais végétation encore sèche en septembre. Épisodes de feux tardifs possibles.

9.2 Importance relative des features

9.2.1 Features les plus corrélées au risk score

L'analyse de corrélation de Pearson entre chaque feature et le risk score sur l'ensemble du dataset méditerranéen révèle une hiérarchie cohérente :

Feature	Corrélation Pearson	Signe
past_hotspot_count	Forte positive (↑)	Mémoire spatiale des feux
past_frp	Forte positive (↑)	Intensité des feux passés
temp_max	Positive modérée	Stress thermique
drought_index	Positive modérée	Stress hydrique
wind_speed	Positive faible	Propagation
ndvi	Négative modérée	Végétation verte = moins de risque
humidity	Négative modérée	Humidité protège
precip	Négative faible	Pluie réduit le risque

9.2.2 Rôle des hotspots passés

La feature `past_hotspot_count` est la plus informative car elle encode la **mémoire spatiale** : les zones historiquement actives ont une probabilité élevée de récurrence, liée aux conditions topographiques et végétales récurrentes. C'est l'équivalent statistique d'un modèle d'auto-régression spatiale.

9.3 Analyse des erreurs

9.3.1 Faux négatifs (événements manqués)

Les événements les plus difficiles à prévoir sont ceux qui surviennent dans des zones **sans historique récent de feux** (première occurrence dans une cellule). Le modèle, privé de signal `past_hotspot_count`, doit compenser par les variables météorologiques et le NDVI.

9.3.2 Faux positifs

Les cellules côtières soumises à des températures élevées mais sans végétation combustible (zones urbaines, littoral rocheux) peuvent générer des faux positifs. L'intégration d'un masque de type de couverture terrestre (Land Cover) serait bénéfique.

9.4 Perspectives d'amélioration

1. **Modèle spatio-temporel** : Un Graph Neural Network (GNN) ou un Transformer spatio-temporel pourrait modéliser les interactions entre cellules voisines, actuellement gérées implicitement via la convolution 3×3 du risk score.
2. **NDVI dynamique** : Intégrer le NDVI VIIRS à résolution journalière (produit VNP13A1) pour capturer les variations inter-annuelles de la végétation.
3. **Couverture terrestre** : Masquer les cellules marines et urbaines avec un masque MODIS Land Cover (MCD12Q1).
4. **Transfert d'apprentissage** : Pré-entraîner sur l'ensemble des données historiques ERA5 (1990–présent) et affiner sur les années récentes.
5. **Calibration probabiliste** : Appliquer une calibration de Platt ou une régression isotonique pour que le score $\hat{y}$ soit interprétable comme une probabilité d'incendie réelle.
6. **Prévision multi-horizons** : Étendre l'architecture pour prédire simultanément les risques à 1, 3, 7 et 14 jours (sortie multi-dimensionnelle).

10. Conclusion

10.1 Bilan du projet

Ce projet a développé un système complet de prédiction du risque d'incendie de forêt dans le bassin méditerranéen, depuis l'acquisition et le traitement des données jusqu'à une interface web interactive. Les contributions principales sont :

1. **Pipeline de données multi-sources** intégrant ERA5 (5 variables atmosphériques), MODIS NDVI (état de la végétation) et NASA FIRMS (détections actives de feux) sur une grille régulière 0.25° couvrant 6 517 cellules du bassin méditerranéen ;
2. **Deux architectures de deep learning** — LSTM bi-couche et TCN à dilations exponentielles — entraînées avec une perte Weighted MSE adaptée au déséquilibre naturel entre cellules à risque et cellules sûres, et évaluées sur un test set temporellement disjoint (2023) ;
3. **Protocole d'évaluation rigoureux** avec split temporel strict, absence de toute fuite d'information entre train et test, et scaler fitté exclusivement sur les données d'entraînement ;
4. **Interface web interactive** permettant la prédiction en temps réel pour tout point géographique de la zone méditerranéenne, la génération de cartes de risque sur l'ensemble de la grille, et la comparaison visuelle des performances des deux modèles ;
5. **Validation sur événements historiques documentés** : les incendies de Gironde 2022, d'Attique 2023, d'Evros 2023 et d'Attique 2024 sont correctement identifiés comme Élevé ou Critique par les deux modèles.

10.2 Apports méthodologiques

D'un point de vue méthodologique, deux contributions sont particulièrement notables :

- La **construction du risk score** par convolution spatiale sur les hotspots futurs + normalisation P99 constitue une formulation élégante du problème qui préserve à la fois la continuité spatiale et la robustesse aux outliers extrêmes ;
- L'approche **DOY-proxy pour le NDVI** (réutilisation de la climatologie 2022 pour les années suivantes par correspondance de jour calendaire) est scientifiquement fondée pour la région méditerranéenne et compatible avec les pratiques des systèmes opérationnels comme EFFIS.

10.3 Perspectives

Le système FireRisk constitue une base solide sur laquelle plusieurs extensions peuvent être construites : intégration de modèles de prévision météorologique NWP (Numerical Weather Prediction) pour étendre l'horizon de prédiction au-delà de la réanalyse, couplage avec des modèles de propagation du feu (FARSITE, Prometheus) pour la gestion opérationnelle des ressources, et extension géographique à d'autres régions à risque (Californie, Australie, Sibérie).

La lutte contre les incendies de forêt dans le contexte du changement climatique requiert des outils d'anticipation de plus en plus sophistiqués. Les systèmes fondés sur le deep learning, capables d'intégrer automatiquement des données hétérogènes et d'apprendre des patterns complexes, représentent une voie prometteuse vers une prédiction plus précoce et plus fiable du risque incendie.

A. Hyperparamètres complets des modèles

Hyperparamètre	LSTM	TCN
Longueur séquence (L)	15	15
Nombre de features (F)	8	8
Taille cachée (H)	64	64 (canaux)
Nombre de couches/blocs	2	4
Taille noyau	—	3
Dilatations	—	{1, 2, 4, 8}
Dropout	0.2	0.2
Tête dense	64→1	32→1
Activation sortie	Sigmoid	Sigmoid
Optimiseur	Adam	Adam
Learning rate	10^{-3}	10^{-3}
Scheduler	ReduceLROnPlateau	ReduceLROnPlateau
Facteur scheduler	0.5	0.5
Patience scheduler	5	5
Taille batch	512	512
Epochs max	100	100
Early stopping patience	10	10
Poids Weighted MSE	10 (si $y > 0.5$)	10 (si $y > 0.5$)

B. Glossaire

AUC-ROC

Area Under the Receiver Operating Characteristic Curve. Mesure la capacité discriminante d'un classifieur binaire. = 1 : discrimination parfaite; = 0.5 : aléatoire.

DOY

Day of Year — numéro du jour dans l'année (1 = 1er janvier, 365 = 31 décembre).

Early Stopping

Arrêt de l'entraînement lorsque la performance de validation ne s'améliore plus après un nombre donné d'époques (patience).

ERA5

Cinquième génération de réanalyse atmosphérique de l'ECMWF. Couvre 1940–présent, résolution 0.25°, données horaires.

FIRMS

Fire Information for Resource Management System (NASA). Fournit des détections thermiques actives de feux en quasi-temps-réel.

FRP

Fire Radiative Power. Puissance radiative du feu mesurée par satellite, en mégawatts. Indicateur de l'intensité d'un incendie actif.

LSTM

Long Short-Term Memory. Architecture de réseau de neurones récurrent avec mécanismes de portes pour apprendre des dépendances à long terme.

MAE

Mean Absolute Error. Erreur absolue moyenne entre prédictions et valeurs réelles.

MODIS

Moderate Resolution Imaging Spectroradiometer. Instrument embarqué sur les satellites Terra et Aqua de la NASA.

NDVI

Normalized Difference Vegetation Index. Indice mesurant la verdure de la végétation depuis l'espace, dans $[-1, 1]$.

NWP

Numerical Weather Prediction. Prévision numérique du temps par simulation des équations de la dynamique atmosphérique.

RMSE

Root Mean Squared Error. Racine de l'erreur quadratique moyenne. Plus sensible aux grandes erreurs que le MAE.

Spearman ρ

Corrélation de rang de Spearman. Mesure la monotonie de la relation entre prédiction et valeur réelle, dans $[-1, 1]$.

TCN

Temporal Convolutional Network. Architecture convolutive causale avec dilations exponentielles pour la modélisation de séquences temporelles.

Weighted MSE

Mean Squared Error pondérée. Variante de la perte MSE qui attribue un poids supérieur aux exemples appartenant à des classes minoritaires.

C. Dépendances logicielles

Package	Version	Rôle
Python	≥ 3.10	Langage
PyTorch	≥ 2.0	Deep learning, entraînement GPU/CPU
Streamlit	≥ 1.30	Interface web interactive
Plotly	≥ 5.18	Visualisations interactives
pandas	≥ 2.0	Manipulation de données tabulaires
numpy	≥ 1.24	Calcul numérique, arrays
xarray	≥ 2023	Lecture NetCDF ERA5
rasterio	≥ 1.3	Lecture GeoTIFF MODIS
scipy	≥ 1.10	Convolution spatiale, Spearman
scikit-learn	≥ 1.3	AUC-ROC
pyarrow	≥ 13.0	Format Parquet

D. Références des données

1. **ERA5** : Hersbach, H. et al. (2020). The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146(730), 1999–2049. <https://doi.org/10.1002/qj.3803>
2. **MODIS NDVI** : Didan, K. (2021). *MODIS/Terra Vegetation Indices Monthly L3 Global 1km SIN Grid V061* [MOD13A3]. NASA EOSDIS Land Processes DAAC. <https://doi.org/10.5067/MODIS/MOD13A3.061>
3. **NASA FIRMS** : Davies, D.K., et al. (2009). Detection of active fires and biomass burning from Landsat-7 ETM+ data. *Remote Sensing of Environment*, 113(1), 69–80. <https://firms.modaps.eosdis.nasa.gov/>
4. **LSTM** : Hochreiter, S. & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
5. **TCN** : Bai, S., Kolter, J.Z. & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. *arXiv :1803.01271*.
6. **EFFIS** : San-Miguel-Ayanz, J. et al. (2012). Comprehensive monitoring of wildfires in Europe : The European Forest Fire Information System (EFFIS). *Approaches to Managing Disaster — Assessing Hazards, Emergencies and Disaster Impacts*, InTech.
7. **Weighted Loss pour déséquilibre** : King, G. & Zeng, L. (2001). Logistic regression in rare events data. *Political Analysis*, 9(2), 137–163.